



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Московский государственный технический университет имени
Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

Отчет по лабораторной работе №5 по курсу "Анализ алгоритмов"

Тема Конвейерная обработка данных

Студент Зайцева А.А.

Группа ИУ7-52Б

Преподаватели Волкова Л.Л.

Москва — 2021 г.

Оглавление

Введение	3
1 Аналитическая часть	4
1.1 Конвейерная обработка данных	4
1.2 Стандартизация данных	4
1.3 Вывод из аналитической части	5
2 Конструкторская часть	6
2.1 Разработка конвейера	6
2.2 Схемы этапов алгоритма стандартизации	7
2.3 Схема линейного алгоритма стандартизации	11
2.4 Схемы параллельной обработки данных конвейером для стандартизации	13
2.5 Вывод из конструкторской части	18
3 Технологическая часть	19
3.1 Выбор средств реализации	19
3.2 Сбор статистики	19
3.3 Реализация алгоритмов	20
3.4 Тестирование	24
3.5 Вывод из технологической части	26
4 Исследовательская часть	27
4.1 Технические характеристики	27
4.2 Сравнение времени выполнения реализаций алгоритмов	27
4.3 Анализ статистики параллельного конвейера	28
4.4 Вывод из исследовательской части	30
Заключение	31
Список использованной литературы	32

Введение

Разработчики архитектуры компьютеров издавна прибегали к методам проектирования, известным под общим названием "совмещение операций при котором аппаратура компьютера в любой момент времени выполняет одновременно более одной базовой операции.

Этот общий метод включает в себя, в частности, такое понятие, как конвейеризация. Конвейеры широко применяются программистами для решения трудоемких задач, которые можно разделить на этапы, а также в большинстве современных быстродействующих процессоров [1].

Целью данной работы является изучение организации конвейерной обработки данных на базе алгоритма стандартизации массива.

В рамках выполнения работы необходимо решить следующие задачи:

- 1) изучить основы конвейеризации;
- 2) изучить алгоритм стандартизации;
- 3) разработать параллельную версию конвейера для стандартизации с 3 стадиями обработки;
- 4) реализовать линейный и параллельный конвейерный варианты стандартизации;
- 5) собрать статистику времени обработки заявок конвейром;
- 6) провести сравнительный анализ времени работы реализаций.

1 Аналитическая часть

В данном разделе будет приведена теория, необходимая для разработки и реализации линейного и параллельного конвейерного вариантов стандартизации массива.

1.1 Конвейерная обработка данных

Конвейеризация (или конвейерная обработка) в общем случае основана на разделении подлежащей исполнению функции на более мелкие части, называемые ступенями, и выделении для каждой из них отдельного блока аппаратуры. Так, обработку любой машинной команды можно разделить на несколько этапов (несколько ступеней), организовав передачу данных от одного этапа к следующему.

Конвейерную обработку можно использовать для совмещения этапов выполнения разных команд. Производительность при этом возрастает благодаря тому, что одновременно на различных ступенях конвейера выполняются несколько команд [2].

1.2 Стандартизация данных

В широком смысле стандартизация данных представляет собой этап их предобработки с целью приведения к определённому формату и представлению [3].

Стандартизация приводит все исходные значения набора данных, независимо от их начальных распределений и единиц измерения, к набору значений из распределения с нулевым средним и стандартным отклонением, равным 1. В результате формируется так называемая стандартизированная шкала, которая определяет место каждого значения в наборе данных. Значения стандартизированной шкалы определяются по формуле (1.1)

$$z_i = \frac{x_i - X_{mean}}{D_x}, \quad (1.1)$$

где x_i — исходное значение признака, $X_{mean} = \frac{sum(x)}{count(x)}$ и $D_x = \sqrt{\frac{sum((x-X_{mean})^2)}{count(x)}}$ — среднее значение и стандартное отклонение признака, оцененные по набору данных [4].

1.3 Вывод из аналитической части

В данном разделе были рассмотрены идеи и материалы, необходимые для разработки и реализации линейного и параллельного конвейерного вариантов стандартизации массива.

2 Конструкторская часть

В данном разделе будет описана структура и принцип работы разрабатываемого конвейера, а также будут приведены схемы для этапов алгоритма стандартизации данных, для линейного алгоритма стандартизации, для главного и рабочих потоков параллельной реализации конвейера.

2.1 Разработка конвейера

Алгоритм стандартизации массива можно разделить на 3 этапа:

- 1) вычисление среднего значения;
- 2) вычисление стандартного отклонения;
- 3) вычисление стандартизованных значений.

Таким образом, конвейер состоит из 3 лент, каждая из которых выполняет соответствующий этап. Для каждой ленты в главном потоке создается отдельный поток.

Рабочий поток выполняется, пока не завершит обработку всех заявок, для чего в него передается общее количество задач, а в нем самом заводится счетчик уже обработанных заявок.

При этом в программе предусмотрен пул обработанных задач и 3 очереди заявок - по одной на каждую ленту. Очередь первой ленты заранее заполняется генератором заявок. Во вторую очередь заявки заносятся первой лентой после выполнения ею назначенной задачи, в третью очередь - второй лентой, в пул обработанных задач - третьей лентой.

Хотя для каждой ленты создана своя очередь, ко 2 и 3 очередям могут одновременно обратиться сразу два потока: предыдущий для записи в нее новой заявки и текущий (соответствующий номеру очереди) для получения новой заявки (в 1 очереди такая ситуация невозможна, так как она заполняется генератором заранее). Поэтому при доступе к элементам 2 и 3 очередей необходимо блокировать доступ для других потоков, для чего используются мьютексы, по одному для каждой очереди.

Для сбора статистики процесса обработки заявок конвейером предусмотрено сохранение информации о времени поступления заявки в очередную очередь и времени выхода из нее.

2.2 Схемы этапов алгоритма стандартизации

На рисунках 2.1 - 2.3 приведены схемы этапов алгоритма стандартизации.




Рисунок 2.1 – Схема этапа поиска среднего значения в массиве




Рисунок 2.2 – Схема этапа поиска стандартного отклонения




Рисунок 2.3 – Схема этапа преобразования (стандартизации) массива

2.3 Схема линейного алгоритма стандартизации

На рисунке 2.4 приведена схема линейного алгоритма обработки заявок на стандартизацию массивов.



Рисунок 2.4 – Схема линейного алгоритма обработки заявок на стандартизацию массивов

2.4 Схемы параллельной обработки данных конвейером для стандартизации

На рисунке 2.5 приведена схема главного потока параллельного конвейера для обработки заявок на стандартизацию массивов, который запускает и контролирует рабочие потоки.




Рисунок 2.5 – Схема главного потока параллельного конвейера

На рисунках 2.6-2.8 приведены схемы рабочих потоков конвейера.

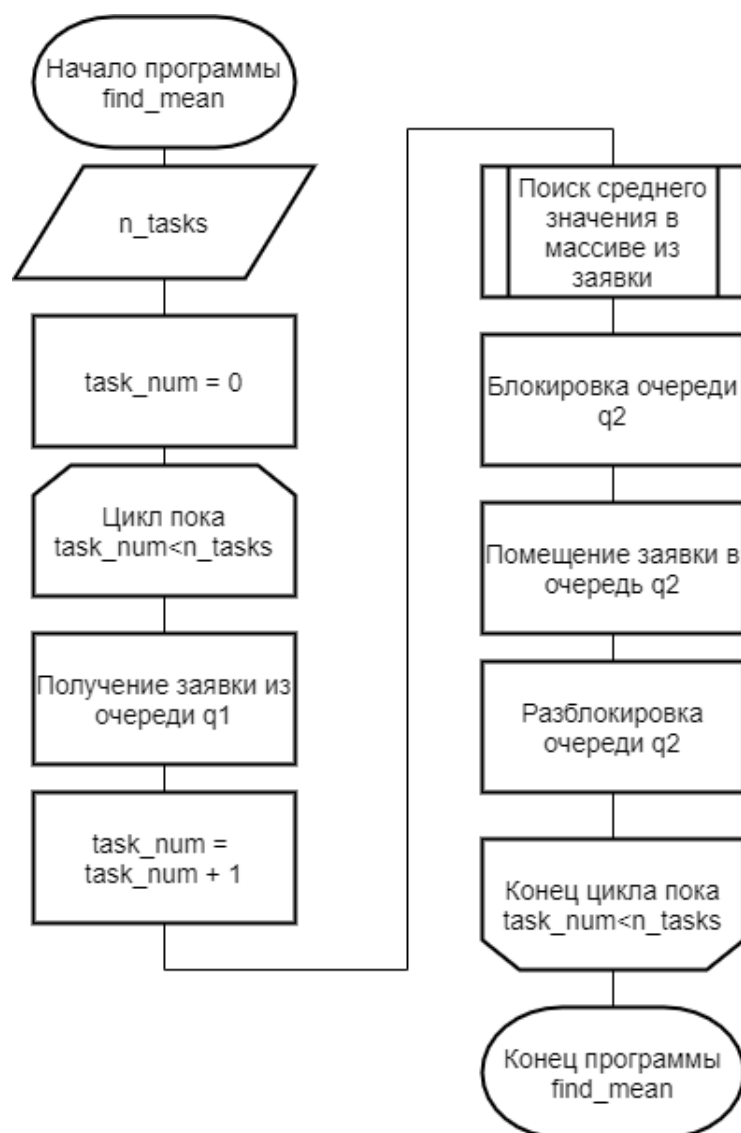


Рисунок 2.6 – Схема потока для поиска среднего значения в массиве

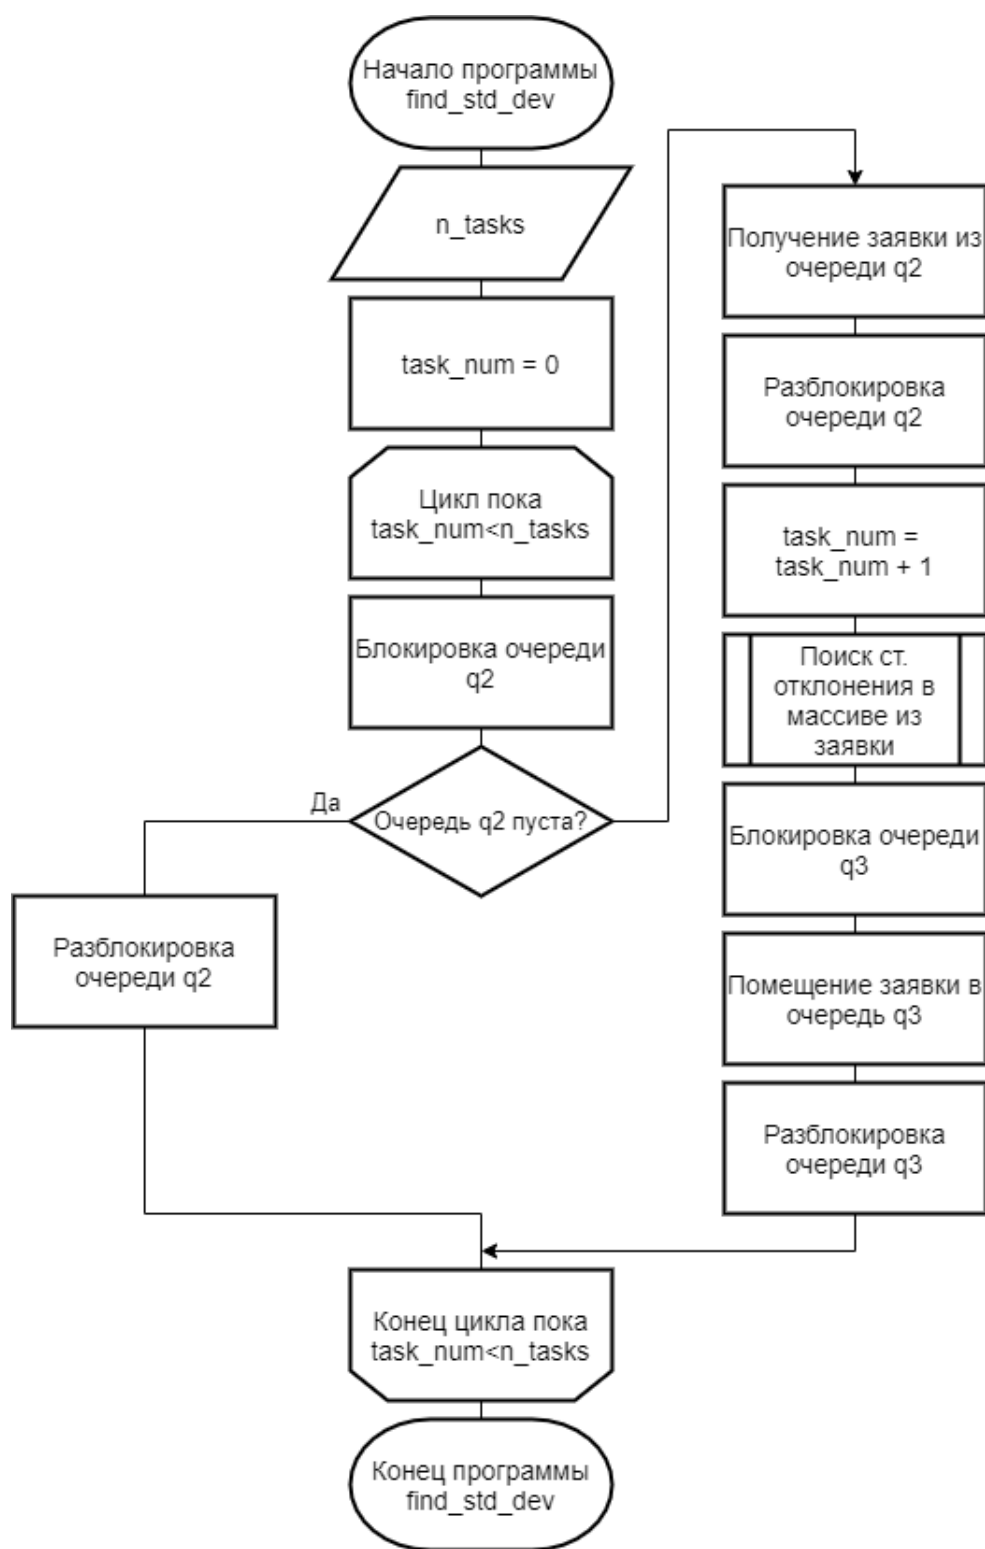


Рисунок 2.7 – Схема потока для поиска стандартного отклонения




Рисунок 2.8 – Схема потока для преобразования (стандартизации) массива

2.5 Вывод из конструкторской части

Была описана структура и принцип работы разрабатываемого конвейера, а также приведены схемы разрабатываемых алгоритмов.

3 Технологическая часть

В данном разделе производится выбор средств реализации, а также приводятся: описание подхода к сбору статистики, листинги реализованных алгоритмов, результаты тестирования программы.

3.1 Выбор средств реализации

Основное требование к языку программирования в данной лабораторной работе - наличие в нем нативных потоков. Язык C++ обладает этим свойством [5] и уже использовался мною ранее, поэтому и был выбран.

Для замеров времени используется предоставляемый класс `system_clock::time_point` использующий данные системных часов в реальном времени [6], а для организации распараллеливания - `std::thread`.

В качестве среды разработки выбран “QT Creator” так как он был часто использован мною ранее.

3.2 Сбор статистики

Чтобы наглядно показать, что ленты конвейера работают параллельно, в класс завок добавлены отметки времени поступления заявки в очередную очередь (или в пул обработанных задач) и времени покидания очередной очереди. В процессе обработки заявок конвейером в лог выводится информация о каждом подобном событии для каждой заявки.

На выходе, когда все заявки обработаны системой, собирается следующая статистика.

- 1) На сколько время обработки N заявок снижено в параллельной реализации конвейера по сравнению с последовательной обработкой одним потоком. Для этого перед запуском и после завершения каждой из реализаций запоминаются данные системных часов в реальном времени, затем второе время вычитается из первого, и получается время работы этой реализации. Далее показания реализаций сравниваются.

- 2) Минимальное, максимальное и среднее время: проведенное заявкой в очереди, проведенное заявкой в системе. Для этого после обработки всех заявок для каждой из них вычисляется время, проведенной в каждой очереди, а также суммарные: время, проведенное в очередях и время, проведенное в системе. Затем вычисляется среднее, максимальное и минимальное каждого из этих значений среди всех заявок.

3.3 Реализация алгоритмов

В листинге 3.1 представлены реализации рабочих потоков параллельного конвейера.

Листинг 3.1 – Реализация рабочих потоков параллельного конвейера

```
1 void Conveyor::find_mean(size_t n_tasks)
2 {
3     size_t task_num = 0;
4
5     while (task_num < n_tasks)
6     {
7         std::shared_ptr<Standardizer> task = q1.front();
8         q1.pop();
9         task->out1 = system_clock::now();
10
11         task->find_mean(++task_num);
12
13         m2.lock();
14         q2.push(task);
15         task->in2 = system_clock::now();
16         m2.unlock();
17     }
18 }
19 void Conveyor::find_std_dev(size_t n_tasks)
20 {
21     size_t task_num = 0;
22
23     while(task_num < n_tasks)
24     {
25         m2.lock();
26         if (!this->q2.empty())
```

```

27     {
28         std::shared_ptr<Standardizer> task = q2.front();
29         q2.pop();
30         task->out2 = system_clock::now();
31         m2.unlock();
32
33         task->find_std_dev(++task_num);
34
35         m3.lock();
36         q3.push(task);
37         task->in3 = system_clock::now();
38         m3.unlock();
39     }
40     else
41         m2.unlock();
42 }
43 }
44 void Conveyor::transform(size_t n_tasks)
45 {
46     size_t task_num = 0;
47
48     while (task_num < n_tasks)
49     {
50         m3.lock();
51         if (!this->q3.empty())
52         {
53             std::shared_ptr<Standardizer> task = q3.front();
54             q3.pop();
55             task->out3 = system_clock::now();
56             m3.unlock();
57
58             task->transform(++task_num);
59
60             tasks.push_back(task);
61             task->out_system = system_clock::now();
62
63         }
64         else
65             m3.unlock();
66     }
67 }

```

В листинге 3.2 представлена реализация главного потока параллельного конвейера.

Листинг 3.2 – Реализация главного потока параллельного конвейера

```
1 void Conveyor::run_parallel(size_t n_tasks, size_t n, double *arr,
2     double *new_arr)
3 {
4     for (size_t i = 0; i < n_tasks; i++)
5     {
6         std::shared_ptr<Standardizer> new_task(new Standardizer(n, arr
7             , new_arr));
8         q1.push(new_task);
9         new_task->in1 = system_clock::now();
10    }
11
12    this->threads[0] = std::thread(&Conveyor::find_mean, this,
13        n_tasks);
14    this->threads[1] = std::thread(&Conveyor::find_std_dev, this,
15        n_tasks);
16    this->threads[2] = std::thread(&Conveyor::transform, this,
17        n_tasks);
18
19    for (size_t i = 0; i < numThreads; i++)
20    {
21        if (this->threads[i].joinable())
22            this->threads[i].join();
23    }
24 }
```

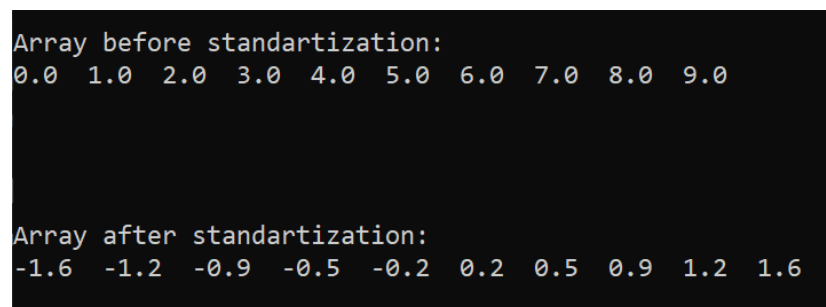
В листинге 3.3 представлена реализация последовательной обработки данных одним потоком.

Листинг 3.3 – Реализация последовательной обработки данных одним
ПОТОКОМ

```
1 void Conveyor::run_linear(size_t n_tasks, size_t n, double *arr,
2     double *new_arr)
3 {
4     for (size_t i = 0; i < n_tasks; i++)
5     {
6         std::shared_ptr<Standardizer> task(new Standardizer(n, arr,
7             new_arr));
8
9         task->find_mean(i + 1);
10        task->find_std_dev(i + 1);
11        task->transform(i + 1);
12
13        tasks.push_back(task);
14    }
15 }
```

3.4 Тестирование

Произведено тестирования алгоритма стандартизации программы по методу черного ящика: проведен запуск программного обеспечения для стандартизации массива из 10 элементов. Содержание массива до и после стандартизации приведено на рисунке 3.1.



```
Array before standartization:
0.0  1.0  2.0  3.0  4.0  5.0  6.0  7.0  8.0  9.0

Array after standartization:
-1.6 -1.2 -0.9 -0.5 -0.2 0.2 0.5 0.9 1.2 1.6
```

Рисунок 3.1 – Результат тестирования алгоритма стандартизации

Как видно на рисунке выше, цель стандартизации достигнута: получен массив с нулевым средним и стандартным отклонением, равным 1.

На рисунке 3.2 приведен пример вывода лога при обработке параллельным конвейером 5 заявок на стандартизацию массива из 100000 элементов.

```

Number of tasks: 5
T 1| P1 | Start| 20:31:04. 68
T 1| P1 | End  | 20:31:04. 76
T 2| P1 | Start| 20:31:04. 81
T 2| P1 | End  | 20:31:04. 87
T 3| P1 | Start| 20:31:04.107
T 3| P1 | End  | 20:31:04.114
T 4| P1 | Start| 20:31:04.151
T 4| P1 | End  | 20:31:04.324
T 5| P1 | Start| 20:31:04.355
T 5| P1 | End  | 20:31:04.362
T 1| P2 | Start| 20:31:04. 81
T 1| P2 | End  | 20:31:04.101
T 2| P2 | Start| 20:31:04.128
T 2| P2 | End  | 20:31:04.144
T 3| P2 | Start| 20:31:04.190
T 3| P2 | End  | 20:31:04.205
T 4| P2 | Start| 20:31:04.355
T 4| P2 | End  | 20:31:04.377
T 5| P2 | Start| 20:31:04.399
T 5| P2 | End  | 20:31:04.415
T 1| P3 | Start| 20:31:04.128
T 1| P3 | End  | 20:31:04.175
T 2| P3 | Start| 20:31:04.230
T 2| P3 | End  | 20:31:04.254
T 3| P3 | Start| 20:31:04.294
T 3| P3 | End  | 20:31:04.317
T 4| P3 | Start| 20:31:04.399
T 4| P3 | End  | 20:31:04.445
T 5| P3 | Start| 20:31:04.497
T 5| P3 | End  | 20:31:04.521

```

Рисунок 3.2 – Результат логирования

Как видно на рисунке выше, заявки действительно обрабатываются параллельно. Например, после завершения обработки первой заявки первым потоком, и ее помещения в очередь второго потока, параллельно начинается обработка второй заявки первым потоком и первой заявки вторым потоком.

На рисунке 3.3 приведен пример вывода собранной статистики при обработке параллельным конвейером 1000 заявок на стандартизацию массива из 100000 элементов.

```

##### STATISTICS (in ms) #####
Time in q1:      min=      1, max=   49726, mean=    25023
Time in q2:      min=      0, max=   11022, mean=     3774
Time in q3:      min=      0, max=   47449, mean=    39298
Total time in queue: min=      1, max=   93975, mean=    68096
Total time in system: min=    131, max=   94094, mean=    68302
##### ENS OF STATISTICS #####

```

Рисунок 3.3 – Пример собранной статистики

На рисунке 3.4 приведен пример вывода результатов сравнения времени выполнения при параллельной и линейной обработке 100 заявок на стандартизацию массива из 100000 элементов.

```
Duration parallel 00:00:10.477 (10477 ms total)
Duration linear 00:00:16.796 (16796 ms total)
Linear realization is 6319 ms (1.603 times) slower than parallel
```

Рисунок 3.4 – Результат сравнения времени выполнения параллельной и линейной реализаций

Более подробно статистика и сравнение времени работы реализаций будут рассмотрены в следующем разделе.

3.5 Вывод из технологической части

Был произведен выбор средств реализации, реализованы и протестированы последовательный и параллельный конвейерный подходы к стандартизации массива.

4 Исследовательская часть

4.1 Технические характеристики

Технические характеристики устройства, на котором выполнялось тестирование:

- операционная система: Windows 10;
- оперативная память: 16 Гб;
- процессор: Intel® Core™ i5-8259U;
- количество ядер: 4;
- количество логических процессоров: 8.

Во время тестирования ноутбук был включен в сеть питания и нагружен только встроенными приложениями окружения и системой тестирования.

4.2 Сравнение времени выполнения реализаций алгоритмов

Сравнивалось время работы (обычное, по таймеру) последовательной стандартизации данных и стандартизации с использованием параллельного конвейера. Эти реализации сравнивались по времени обработки заявок на стандартизацию массива вещественных чисел из 10000 элементов в зависимости от количества заявок: 1, 5, 25 и от 50 до 250 с шагом 50.

Так как некоторые задачи выполняются достаточно быстро, а замеры времени имеют некоторую погрешность, они для каждой реализации и каждого количества заявок выполнялись 10 раз, а затем вычислялось среднее время работы.

На рисунке 4.1 приведены результаты сравнения времени выполнения реализаций алгоритмов.




Рисунок 4.1 – Сравнение времени работы реализаций в зависимости от количества заявок

Как и ожидалось, параллельная реализация выполняется за меньшее количество времени в сравнении с линейной за счет того, что в ней одновременно на разных лентах (потоках) обрабатываются несколько заявок. Причем с ростом числа заявок разрыв между реализациями увеличивается.

4.3 Анализ статистики параллельного конвейера

На рисунке 4.2 приведен результат сбора статистики при обработке 1000 заявок на обработку массива из 100000 элементов.

```
##### STATISTICS (in ms) #####
Time in q1:      min=      1, max=    49726, mean=    25023
Time in q2:      min=      0, max=    11022, mean=     3774
Time in q3:      min=      0, max=    47449, mean=    39298
Total time in queue: min=      1, max=    93975, mean=    68096
Total time in system: min=    131, max=    94094, mean=    68302
##### ENS OF STATISTICS #####
```

Рисунок 4.2 – Результат сбора статистики

Как видно из рисунка, очереди с наибольшим максимальным временем нахождения в них заявки – первая и третья. Для первой очереди такой результат объясняется тем, что она заполняется генератором заранее, и последняя заявка находится в ней до того момента, пока все предшествующие ей не будут обработаны первой лентой. Это подтверждает и среднее время, проведенное заявкой в первой очереди, которое приблизительно равно половине от максимального.

Для третьей же очереди наибольшее максимальное (и, в частности, среднее) время нахождения в ней заявки связано со сложностью работы соответствующей ей ленты. Она преобразовывает исходный массив, записывая полученные в результате вычитаний и делений новые значения в результирующий массив, на что тратится большое количество операций и, соответственно, время.

Минимальное время нахождения заявки в каждой очереди соответствует отметкам первой задачи: в каждую ленту она попадает сразу же, не ожидая окончания обработки в этом потоке предыдущей задачи.

Вычитая из минимального времени, проведенного заявкой в системе, минимальное суммарное время, проведенное заявкой в очередях, можно вычислить время обработки этой заявки, равное 130 мс.

При этом можно заметить, что минимальное, максимальное и среднее время, проведенное заявкой в системе слабо отличается от тех же замеров для времени, проведенного заявкой в очередях. Это, а также анализ времени, проведенного заявками в третьей очереди, еще раз подтверждает, что при организации параллельного конвейера необходимо разбивать задачу на этапы, схожие по трудоемкости, иначе большую часть времени заявки будут простаивать в очередях.

4.4 Вывод из исследовательской части

Таким образом, параллельная организация обработки данных с использованием конвейера работает быстрее, чем линейная обработка. При этом для достижения наилучших показателей необходимо корректно разделять задачу на этапы: так, чтобы время их выполнения было приблизительно равным, иначе большую часть времени заявки будут простаивать в очереди наиболее трудоемкой ленты.

Заключение

В результате выполнения лабораторной работы была достигнута поставленная цель: были изучены основы организации конвейерной обработки данных на базе алгоритма стандартизации массива.

В ходе выполнения лабораторной работы были выполнены следующие задачи:

- 1) изучены основы конвейеризации;
- 2) изучен алгоритм стандартизации;
- 3) разработана параллельная версия конвейера для стандартизации с 3 стадиями обработки;
- 4) реализован линейный и параллельный конвейерный варианты стандартизации;
- 5) собрана статистика времени обработки заявок конвейром;
- 6) проведен сравнительный анализ времени работы реализаций.

Литература

- [1] Принципы конвейерной технологии [Электронный ресурс]. Режим доступа: <https://www.sites.google.com/site/shoradimon/18-principy-konvejernoj-tehnologii> (дата обращения: 19.10.2021).
- [2] Аппаратное ускорение для OpenGL [Электронный ресурс]. Режим доступа: <https://www.osp.ru/os/1997/02/179130> (дата обращения: 19.10.2021).
- [3] Стандартизация данных (Data standardization) [Электронный ресурс]. Режим доступа: <https://wiki.loginom.ru/articles/data-standartization.html> (дата обращения: 19.10.2021).
- [4] Стандартное отклонение [Электронный ресурс]. Режим доступа: <https://www.uznaychtotakoe.ru/standartnoe-otklonenie/> (дата обращения: 19.10.2021).
- [5] Thread support library [Электронный ресурс]. Режим доступа: <https://en.cppreference.com/w/cpp/thread> (дата обращения: 20.10.2021).
- [6] Структура systemclock [Электронный ресурс]. Режим доступа: <https://docs.microsoft.com/ru-ru/cpp/standard-library/system-clock-structure?view=msvc-160> (дата обращения: 20.10.2021).